



UNIVERSIDAD DE
CUNDINAMARCA
Generación Siglo 21

INFORME DE REGRESIÓN LOGÍSTICA

*Clasificación de tumores de mama en malignos y benignos con regresión logística:
selección de variables, ajuste del umbral e incertidumbre de los resultados*

Repositorio del trabajo en GitHub:

<https://github.com/Danielleon172025/regresion-logistica-cancer>

PRESENTADO POR:

DANIEL FELIPE LEÓN HIGUERA

INTRODUCCIÓN A MACHINE LEARNING

UNIVERSIDAD DE CUNDINAMARCA

CHÍA, OCTUBRE DE 2026

TABLA DE CONTENIDO

Resumen ejecutivo	3
1. Introducción	3
1.1 Contexto y planteamiento del problema	3
1.2 Objetivos	3
2. Marco conceptual	4
2.1 Regresión logística	4
2.2 Umbral de decisión y matriz de confusión	4
2.3 Métricas de evaluación	4
3. Metodología	4
3.1 Datos	4
3.2 Partición de los datos	5
3.3 Selección de variables por colinealidad	5
3.4 Modelo y justificación de los parámetros	5
3.5 Selección de C y ajuste del umbral	5
3.6 Evaluación e incertidumbre	6
3.7 Entorno y reproducibilidad	6
4. Resultados	6
4.1 Exploración de los datos	6
4.2 Selección de variables y de C	8
4.3 Comparación de variantes	10
4.4 Umbral de decisión	10
4.5 Desempeño en el conjunto de prueba	11
4.6 Interpretación de los coeficientes	12
5. Discusión	13
6. Conclusiones	14
7. Repositorio y control de versiones	14
8. Referencias	14

Resumen ejecutivo

Este informe documenta un modelo de regresión logística para un problema de clasificación binaria. Con el conjunto público *Breast Cancer Wisconsin (Diagnostic)* (569 muestras de tejido mamario descritas por medidas del núcleo celular) se predice si un tumor es maligno. La clase positiva es *maligno*, de modo que el recall mide la proporción de tumores malignos detectados.

Las variables se seleccionaron por colinealidad (VIF) y quedaron cinco: radio, textura, suavidad, concavidad, simetría. El hiperparámetro C (0,1) se eligió por validación cruzada con la regla de un error estándar, y el umbral de decisión (0,285) se ajustó con la métrica F2, siempre solo con el conjunto de entrenamiento. En el conjunto de prueba (143 casos), el AUC es 0,987 (IC 95 %: 0,973 a 0,997). Con el umbral por defecto (0,50) el modelo deja pasar 7 de 53 tumores malignos; con el umbral ajustado deja pasar 2, a costa de subir las falsas alarmas de 2 a 9. El aumento del recall (0,094; IC 95 %: 0,033 a 0,177) y la caída de la precisión (0,108) se mantienen en un bootstrap pareado. Las cinco variables se eligieron por interpretabilidad: con las 30 originales el modelo rinde mejor en validación cruzada.

1. Introducción

1.1 Contexto y planteamiento del problema

El cáncer de mama fue el cáncer más frecuente en las mujeres colombianas entre los once tipos priorizados por la Cuenta de Alto Costo, con una mediana de edad al diagnóstico de 59 años en los casos nuevos de 2023 (Cuenta de Alto Costo, 2024). A escala mundial, la Organización Mundial de la Salud estima 2,4 millones de diagnósticos en mujeres y 694 000 muertes en 2024 (Organización Mundial de la Salud, 2026). Clasificar tumores a partir de medidas de una biopsia sirve como caso de estudio porque los dos errores posibles no cuestan lo mismo: pasar por alto un tumor maligno (falso negativo) es más grave que pedir un examen adicional para uno benigno (falso positivo).

El modelo tiene fines académicos: no sustituye el diagnóstico de un patólogo ni está validado para uso clínico.

1.2 Objetivos

El objetivo general es diseñar, implementar y documentar un ejercicio completo de regresión logística que recorra todo el proceso de un problema de clasificación, desde la preparación de los datos hasta la interpretación del modelo.

Los objetivos específicos son:

- Explorar los datos y seleccionar las variables con un criterio explícito de colinealidad.
- Entrenar el modelo con parámetros justificados y compararlo con una línea base y con otras variantes mediante validación cruzada.
- Evaluar el modelo en un conjunto de prueba con exactitud, precisión, recall, especificidad, F1, AUC y matriz de confusión, y cuantificar su incertidumbre.
- Ajustar el umbral de decisión según el costo de los errores y discutir sus consecuencias.

- Publicar el código y el notebook en un repositorio versionado y reproducible.

2. Marco conceptual

2.1 Regresión logística

La regresión logística es un algoritmo de aprendizaje supervisado para resultados categóricos: estima la probabilidad de que una observación pertenezca a una clase a partir de un conjunto de variables independientes (Lee, 2025). Combina las variables en una suma ponderada y la pasa por la función sigmoide, una curva en forma de S que lleva cualquier valor al intervalo entre 0 y 1 (Google for Developers, 2026b). Para entrenarla se usa la pérdida logística, y la regularización evita que el modelo se sobreajuste: la regularización L2 penaliza los coeficientes grandes (Google for Developers, 2026b).

Los coeficientes se interpretan en términos de *log-odds*. Por cada aumento de una unidad en una variable, las probabilidades del resultado se multiplican por e elevado al coeficiente, que es la razón de momios; un coeficiente positivo aumenta las probabilidades del evento y uno negativo las reduce (Lee, 2025).

2.2 Umbral de decisión y matriz de confusión

El modelo entrega una probabilidad; el umbral de clasificación es el valor a partir del cual esa probabilidad se convierte en la clase positiva (Google for Developers, 2025d). Con un umbral alto el modelo rara vez marca un caso negativo como positivo, pero tiende a omitir positivos reales; con un umbral bajo ocurre lo contrario. La matriz de confusión resume los cuatro resultados posibles: verdaderos positivos, falsos positivos, falsos negativos y verdaderos negativos (Google for Developers, 2025d).

2.3 Métricas de evaluación

La *exactitud* es la proporción de clasificaciones correctas. El *recall* (tasa de verdaderos positivos) es la proporción de los positivos reales que el modelo identifica, y conviene priorizarlo cuando los falsos negativos son más costosos que los falsos positivos. La *precisión* es la proporción de las clasificaciones positivas que realmente lo son (Google for Developers, 2026a). La *especificidad* es el recall de la clase negativa. En conjuntos con clases desequilibradas la exactitud suele ser una métrica deficiente (Google for Developers, 2025b; 2026a). La curva ROC grafica la tasa de verdaderos positivos frente a la de falsos positivos en todos los umbrales, y el AUC es la probabilidad de que el modelo ordene un positivo elegido al azar por encima de un negativo elegido al azar; vale 0,5 para un modelo equivalente al azar y 1,0 para uno perfecto (Google for Developers, 2025a). Estas métricas son las habituales para evaluar clasificadores (Romero Ibarra, 2025). La F2 es una media de precisión y recall que pesa el recall cuatro veces más que la precisión.

3. Metodología

3.1 Datos

Los datos son el *Breast Cancer Wisconsin (Diagnostic) Data Set*, publicado en el repositorio UCI por Wolberg, Street y Mangasarian en 1995 e incluido en Scikit-learn mediante `load_breast_cancer`. Contiene 569 muestras de biopsias por aspiración con aguja fina, digitalizadas, con diagnóstico confirmado y 30

variables numéricas calculadas sobre los núcleos celulares. No tiene valores nulos. Hay 357 casos benignos (62,7 %) y 212 malignos (37,3 %).

Scikit-learn codifica 0 como maligno y 1 como benigno. Se invirtió la codificación (`maligno = 1`) para que la clase positiva sea la de interés clínico. Se partió de seis variables candidatas, todas promedios del núcleo celular: radio, textura, suavidad, concavidad, puntos cóncavos y simetría. Se excluyeron de entrada el perímetro y el área, que duplican el radio (correlación de 0,99 con él).

3.2 Partición de los datos

Los datos se dividieron de forma estratificada en entrenamiento (426 casos, 75 %) y prueba (143 casos, 25 %), con semilla fija (42). La partición se hizo antes de cualquier decisión basada en los datos, y el conjunto de prueba se usó una sola vez, al final: cuanto más se reutilizan esos datos para decidir configuraciones, menos confianza merece el resultado (Google for Developers, 2025c).

3.3 Selección de variables por colinealidad

Con variables muy correlacionadas el modelo puede predecir bien, pero sus coeficientes individuales son inestables. Se calculó el factor de inflación de la varianza (VIF) de cada variable a partir de la inversa de la matriz de correlación, y se aplicó una eliminación iterativa: se quita la variable con mayor VIF y se recalcula, hasta que todas queden por debajo de 5. El cálculo usó solo el conjunto de entrenamiento.

3.4 Modelo y justificación de los parámetros

Parámetro	Valor	Justificación
Escalado	StandardScaler	Las variables tienen escalas muy distintas (el radio va de 7 a 28 y la suavidad de 0,05 a 0,16); sin escalar, la regularización penalizaría de forma desigual cada coeficiente. Se ajusta solo con el entrenamiento, dentro del Pipeline.
Regularización	L2 (por defecto)	Reduce el sobreajuste y estabiliza los coeficientes (Google for Developers, 2026b).
C	elegido por validación cruzada	Inverso de la fuerza de regularización. Ver sección 3.5.
solver	lbfgs (por defecto)	Apropiado para pocas variables y unos cientos de observaciones.
max_iter	1000	Holgado: el solver converge en 8 iteraciones.
class_weight	ninguno	El desbalance es moderado (37 % de malignos). El costo asimétrico de los errores se trata con el umbral; la alternativa balanced se compara en la sección 4.3.
random_state	42	Reproducibilidad.

3.5 Selección de C y ajuste del umbral

Para elegir C se evaluó cada valor entre 0,01 y 100 con validación cruzada estratificada de 5 pliegos, usando el AUC porque no depende del umbral. Como diferencias de milésimas entre valores grandes de C son ruido, se aplicó la regla de un error estándar: se elige el menor C (el más regularizado) cuyo AUC medio no se aleja del mejor más de un error estándar, es decir, la desviación dividida entre la raíz del número de pliegos.

El umbral se buscó con `TunedThresholdClassifierCV`, que prueba umbrales dentro de la validación cruzada del entrenamiento y conserva el que maximiza la F2. Se eligió F2 porque en este problema el recall pesa más que la precisión. El peso es una decisión de política clínica: otro peso daría otro umbral.

3.6 Evaluación e incertidumbre

En el conjunto de prueba se calcularon exactitud, exactitud balanceada, precisión, recall, especificidad, F1, F2, coeficiente de correlación de Matthews, AUC-ROC, AUC-PR y puntaje de Brier. Como 143 casos dan cifras poco estables, se estimaron intervalos de confianza del 95 % por bootstrap percentil (1000 remuestras con reposición). La diferencia entre los dos umbrales se evaluó con un bootstrap pareado, es decir, sobre las mismas remuestras, porque dos intervalos calculados por separado no permiten saber si una diferencia es real. Los intervalos de las razones de momios salen de reajustar el modelo en 500 remuestras del entrenamiento.

3.7 Entorno y reproducibilidad

El notebook se ejecuta en Google Colab con scikit-learn 1.5 o superior. Los resultados de este informe se generaron con los scripts de `src/` en Python 3.14.3, NumPy 2.4.4, pandas 3.0.2 y scikit-learn 1.8.0. Las semillas están fijas, así que el notebook y los scripts producen las mismas cifras.

4. Resultados

4.1 Exploración de los datos

La distribución de clases se muestra en la Figura 1. Los tumores malignos tienen valores más altos en todas las variables (Figura 2): el radio promedio es 12,1 en los benignos y 17,5 en los malignos. Radio, concavidad y puntos cóncavos son las variables que más separan las clases, con solapamiento moderado; textura, suavidad y simetría se solapan mucho más.




Figura 1. Distribución de las clases ($n = 569$).

Distribución de cada variable según el diagnóstico




Figura 2. Distribución de cada variable candidata según el diagnóstico.

Las correlaciones entre candidatas son altas (Figura 3): concavidad con puntos cóncavos 0,92, radio con puntos cóncavos 0,82 y radio con concavidad 0,68. La Figura 4 muestra la separación entre clases en el plano radio y concavidad; los casos intermedios, donde se mezclan los colores, son los que más dudas darán al modelo.




Figura 3. Correlación de Pearson entre las variables candidatas.




Figura 4. Radio y concavidad según el diagnóstico.

4.2 Selección de variables y de C

Con las seis candidatas, *puntos cóncavos* tiene un VIF de 22,6 y es la primera en eliminarse. Con las cinco restantes, el mayor VIF es 3,1 (concavidad) y el procedimiento se detiene.

Tabla 1. VIF antes y después de la eliminación (entrenamiento).

Variable	VIF con las 6 candidatas	VIF con las variables finales
radio	7,0	2,1
textura	1,1	1,1
suavidad	2,7	1,8
concavidad	8,2	3,1
puntos cóncavos	22,6	eliminada
simetría	1,7	1,7

En cuanto a C, el AUC medio apenas cambia a partir de $C = 0,3$ (Tabla 2 y Figura 5). La regla de un error estándar elige $C = 0,1$, cuyo AUC (0,980) está dentro de un error estándar del máximo (0,982). El recall con umbral 0,50 sí crece con C, pero eso se corrige ajustando el umbral.

Tabla 2. Selección de C por validación cruzada (5 pliegos, entrenamiento).

C	AUC medio	Desv. est.	Recall medio	Precisión media
0,01	0,975	0,010	0,737	0,972
0,03	0,978	0,008	0,799	0,969
0,1	0,980	0,006	0,849	0,971
0,3	0,981	0,006	0,862	0,940
1	0,982	0,007	0,874	0,927
3	0,982	0,007	0,893	0,929
10	0,982	0,007	0,893	0,923
30	0,982	0,007	0,893	0,923
100	0,982	0,007	0,893	0,923




Figura 5. AUC en validación cruzada para cada valor de C.

4.3 Comparación de variantes

Tabla 3. Comparación de variantes en validación cruzada (5 pliegos, entrenamiento, umbral 0,50). Media $\pm$ desviación estándar.

Modelo	Exactitud	Precisión	Recall	F1	AUC
Línea base (siempre benigno)	0,627 $\pm$ 0,005	0,000 $\pm$ 0,000	0,000 $\pm$ 0,000	0,000 $\pm$ 0,000	0,500 $\pm$ 0,000
Regresión logística, 5 variables finales, C=0,1	0,934 $\pm$ 0,025	0,971 $\pm$ 0,015	0,849 $\pm$ 0,060	0,905 $\pm$ 0,039	0,980 $\pm$ 0,006
Regresión logística, 5 variables finales, C=0,1, pesos balanceados	0,927 $\pm$ 0,020	0,911 $\pm$ 0,021	0,893 $\pm$ 0,058	0,901 $\pm$ 0,030	0,980 $\pm$ 0,006
Regresión logística, 6 candidatas (con colinealidad), C=0,1	0,934 $\pm$ 0,016	0,958 $\pm$ 0,013	0,862 $\pm$ 0,042	0,907 $\pm$ 0,024	0,982 $\pm$ 0,006
Regresión logística, 30 variables, C=0,1	0,967 $\pm$ 0,009	0,993 $\pm$ 0,013	0,918 $\pm$ 0,025	0,954 $\pm$ 0,013	0,992 $\pm$ 0,006

La línea base (decir siempre "benigno") acierta el 62,7 % pero detecta 0 % de los malignos y tiene AUC 0,5. Los pesos balanceados suben el recall y bajan la precisión con el mismo AUC, un intercambio equivalente a bajar el umbral. Añadir *puntos cóncavos* (seis candidatas) casi no mejora el AUC, lo que respalda eliminarla. El modelo con las 30 variables es claramente mejor (AUC 0,992 y recall 0,918 frente a 0,980 y 0,849): es el costo, en desempeño, de haber elegido un modelo con coeficientes legibles.

4.4 Umbral de decisión

El umbral elegido por validación cruzada es 0,285. La Figura 6 muestra cómo se mueven el recall, la precisión y la F2 con las probabilidades fuera de muestra del entrenamiento. Un umbral menor que 0,5 exige menos evidencia para marcar un caso como sospechoso.




Figura 6. Recall, precisión y F2 según el umbral, con predicciones fuera de muestra del entrenamiento.

4.5 Desempeño en el conjunto de prueba

Tabla 4. Métricas en el conjunto de prueba (n = 143; clase positiva: maligno).

Métrica	Umbral 0,50	Umbral ajustado (0,285)
Verdaderos negativos / falsos positivos	88 / 2	81 / 9
Falsos negativos / verdaderos positivos	7 / 46	2 / 51
Exactitud	0,937	0,923
Recall (sensibilidad)	0,868	0,962
Especificidad	0,978	0,900
Precisión	0,958	0,850
F1	0,911	0,903
F2	0,885	0,938
Coeficiente de correlación de Matthews	0,865	0,844
AUC-ROC	0,987	0,987
AUC-PR (precisión promedio)	0,981	0,981
Puntaje de Brier	0,051	0,051




Figura 7. Matrices de confusión en el conjunto de prueba con ambos umbrales.

Con el umbral 0,50, el modelo detecta 46 de 53 tumores malignos y deja pasar 7; solo marca 2 casos benignos como malignos. Con el umbral 0,285 detecta 51 y deja pasar 2, pero marca 9 benignos como malignos. En términos clínicos, 5 tumores malignos más detectados a cambio de 7 exámenes adicionales sobre casos benignos.

Tabla 5. Intervalos de confianza del 95 % por bootstrap (1000 remuestras).

Métrica	Umbral 0,50 (IC 95 %)	Umbral 0,285 (IC 95 %)
Recall	0,868 [0,771; 0,945]	0,962 [0,902; 1,000]
Precisión	0,958 [0,894; 1,000]	0,850 [0,750; 0,930]
AUC-ROC	0,987 [0,973; 0,997]	0,987 [0,973; 0,997]

Para comparar los umbrales se usó el bootstrap pareado: el recall aumenta 0,094 (IC 95 %: 0,033 a 0,177) y la precisión disminuye 0,108 (IC 95 %: -0,196 a -0,038). Ambos intervalos excluyen el cero, así que el intercambio se mantiene al remuestrear los casos de prueba. El AUC no depende del umbral y vale 0,987; el puntaje de Brier es 0,051, frente a unos 0,23 de un modelo que predijera siempre la prevalencia.




Figura 8. Curvas ROC y precisión-recall en el conjunto de prueba.

4.6 Interpretación de los coeficientes

Como las variables están estandarizadas, los coeficientes son comparables. Los cinco son positivos: valores más altos de cualquiera de las variables aumentan las probabilidades de maligno. El radio domina, con una razón de momios de 6,0 por cada desviación estándar (IC 95 %: 5,0 a 7,3). Le siguen concavidad (2,4), textura (2,2) y suavidad (1,8). La simetría es la más débil (1,3), con un intervalo (1,05 a 1,59) que casi toca 1.

Tabla 6. Coeficientes, razones de momios e intervalos (por +1 desviación estándar).

Variable	Coeficiente	Razón de momios	IC 95 % (bootstrap)	VIF
radio	1,799	6,04	[4,96; 7,30]	2,10
concavidad	0,862	2,37	[1,84; 3,24]	3,09
textura	0,769	2,16	[1,83; 2,54]	1,15
suavidad	0,593	1,81	[1,48; 2,19]	1,78
simetría	0,245	1,28	[1,05; 1,59]	1,68




Figura 9. Razones de momios con intervalo de confianza del 95 % (escala logarítmica).

5. Discusión

El AUC de 0,987 indica que el modelo ordena casi siempre un tumor maligno por encima de uno benigno, incluso con cinco variables. Aun así, con el umbral por defecto el 13 % de los malignos pasa inadvertido, una cifra difícil de aceptar si el modelo apoyara un diagnóstico. La exactitud de 0,937 no deja ver esa omisión, y por eso el recall es la métrica central (Google for Developers, 2026a).

Bajar el umbral no cambia el AUC y solo redistribuye los errores: se omiten menos malignos y se marcan más benignos sin serlo. Que el intercambio resulte favorable depende del peso asignado al recall (F2), y esa decisión corresponde al personal clínico.

Con 143 casos de prueba los intervalos son amplios: el recall con umbral 0,50 podría estar entre 0,771 y 0,945. El bootstrap pareado indica que la mejora del recall con el umbral ajustado se mantiene al remuestrear, aunque su magnitud exacta sigue siendo incierta.

Eliminar *puntos cóncavos* por colinealidad costó poco (AUC 0,982 con las seis candidatas frente a 0,980) y dio coeficientes con intervalos estrechos. Con las 30 variables el AUC sube a 0,992, pero al estar tan correlacionadas sus coeficientes dejarían de poder leerse. Si solo importa predecir, conviene el modelo completo; si importa explicar qué pesa en la decisión, el reducido.

Las limitaciones del trabajo son las siguientes:

- Los datos provienen de un único centro y de un protocolo de digitalización de imágenes de 1995; no hay garantía de que el modelo funcione igual con otros equipos o poblaciones.
- El conjunto de prueba es pequeño (143 casos, 53 malignos).
- No se evaluó la calibración de las probabilidades; el puntaje de Brier es un resumen, no una curva de calibración.
- El umbral depende del peso elegido para el recall (F2).
- Las razones de momios son asociaciones del modelo, no efectos causales.
- El modelo tiene fines académicos y no está validado para uso clínico.

6. Conclusiones

- La regresión logística con cinco variables sin colinealidad (VIF máximo de 3,1) separa muy bien los tumores malignos de los benignos: AUC 0,987 en el conjunto de prueba.
- Con el umbral por defecto el modelo omite 7 de 53 tumores malignos pese a una exactitud de 0,937; el recall y la matriz de confusión describen mejor su desempeño.
- Ajustar el umbral con F2, usando solo el entrenamiento, reduce las omisiones a 2 a cambio de 7 falsas alarmas adicionales, y el cambio se sostiene en un bootstrap pareado.
- Cada parámetro del modelo se justificó con validación cruzada o con una razón explícita, y los empates se resolvieron con una regla fija (un error estándar).
- Los coeficientes son legibles y coherentes con el contexto clínico: el radio del núcleo es la variable que más pesa.

Quedan como trabajo futuro la curva de calibración, la validación con datos de otros centros, la comparación con árboles de decisión, Random Forest y SVM (Semanas 7 y 8) y la definición del umbral junto con criterios clínicos.

7. Repositorio y control de versiones

El código, el notebook y este informe están en <https://github.com/Danielleon172025/regresion-logistica-cancer>. La estructura es la siguiente:

```
regresion-logistica-cancer/  
├── README.md           descripción, instalación y resultados  
├── requirements.txt     dependencias  
├── notebooks/          notebook de Colab ejecutado, con salidas  
├── src/                pipeline modular (datos, modelo, evaluación, gráficos)  
└── Informe_RegresionLogistica_LeonHigueraDanielFelipe.pdf
```

Para reproducir el trabajo se necesita Python 3.10 o superior: `pip install -r requirements.txt`, `python src/main.py` para ejecutar el pipeline, que genera las tablas y las figuras en local. El notebook se abre en Colab y se ejecuta de principio a fin.

El proyecto se gestiona con Git. El historial de cambios se consulta con `git log`.

8. Referencias

- Cuenta de Alto Costo. (2024, 19 de octubre). *Día mundial del cáncer de mama*. <https://cuentadealtocosto.org/noticias/dia-mundial-del-cancer-de-mama/>
- Google for Developers. (2025a, 1 de octubre). *Clasificación: ROC y AUC*. Curso intensivo de aprendizaje automático. <https://developers.google.com/machine-learning/crash-course/classification/roc-and-auc?hl=es-419>
- Google for Developers. (2025b, 28 de agosto). *Conjuntos de datos: Conjuntos de datos con desequilibrio de clases*. Curso intensivo de aprendizaje automático. <https://developers.google.com/machine-learning/crash-course/overfitting/imbalanced-datasets?hl=es-419>

- Google for Developers. (2025c, 3 de enero). *Conjuntos de datos: división del conjunto de datos original*. Curso intensivo de aprendizaje automático. <https://developers.google.com/machine-learning/crash-course/overfitting/dividing-datasets?hl=es-419>
- Google for Developers. (2025d, 1 de octubre). *Umbral y matriz de confusión*. Curso intensivo de aprendizaje automático. <https://developers.google.com/machine-learning/crash-course/classification/thresholding?hl=es-419>
- Google for Developers. (2026a, 5 de febrero). *Clasificación: Exactitud, recuperación, precisión y métricas relacionadas*. Curso intensivo de aprendizaje automático. <https://developers.google.com/machine-learning/crash-course/classification/accuracy-precision-recall?hl=es-419>
- Google for Developers. (2026b, 12 de mayo). *Regresión logística: pérdida y regularización*. Curso intensivo de aprendizaje automático. <https://developers.google.com/machine-learning/crash-course/logistic-regression/model-training?hl=es-419>
- Lee, F. (2025, 14 de mayo). *¿Qué es la regresión logística?* IBM. <https://www.ibm.com/mx-es/topics/logistic-regression>
- Organización Mundial de la Salud. (2026, 3 de julio). *Cáncer de mama* [Nota descriptiva]. <https://www.who.int/es/news-room/fact-sheets/detail/breast-cancer>
- Romero Ibarra, J. L. (2025). Análisis integral de algoritmos de clasificación en aprendizaje automático: perspectivas, comparaciones y aplicaciones. *Serie Científica de la Universidad de las Ciencias Informáticas*, 18(1), 283-304. http://scielo.sld.cu/scielo.php?pid=S2306-24952025000100283&script=sci_abstract